

Prueba Técnica — Ingeniero Senior Cloud

Campo	Valor
Cargo	Ingeniero Senior Cloud
Reporta a	Subgerente Cloud
Duración sugerida	2.5 - 3 horas
Modalidad	Presencial o remota
Uso de IA	Permitido y esperado (se evalúa el criterio, no la memoria)

Instrucciones para el Candidato

Este ejercicio evalúa tu criterio de ingeniería en operación cloud, no tu capacidad de memorizar comandos. Puedes usar IA (Chat GPT, Copilot, etc.), documentación de AWS y buscadores. Lo que evaluamos es como razonas, decides y justificas ante escenarios reales de operación, seguridad, automatización (IaC/CI-CD), resiliencia y optimización de costos.

Reglas:

- Explica el **porqué** de cada decisión, no solo el **cómo**.
- Cuando uses IA, indica que te sugirió y como validaste o ajustaste esa sugerencia.
- Si una pregunta no tiene una única respuesta correcta, plantea las opciones y justifica tu elección con tradeoffs (costo, riesgo, tiempo, seguridad).
- Prioriza soluciones seguras, reversibles y auditables.

Contexto tecnológico de la compañía (para situar los escenarios):

- Nube principal: AWS (organización multi-cuenta con segmentación hub / dev / qat / prd).
- IaC: Terraform (módulos, state en S3).
- CI/CD: Azure DevOps con autenticación OIDC (sin access keys estáticas).
- Patrón de despliegue: pipeline asume un rol OIDC intermedio en la cuenta de herramientas DevOps (hub), que a su vez asume un rol de deploy en la cuenta destino (cross-account).
- Servicios en uso: VPC, EC2, RDS, Lambda, EKS/Fargate, CloudFront, WAF, Route 53, S3, Glue, Athena, Redshift, KMS, Secrets Manager, CloudWatch.

Bloque 1 — Aprovisionamiento y Automatización (IaC + CI/CD)

Evalúa: Terraform avanzado, módulos, state, pipelines OIDC, cross-account.

Caso 1.1 — Nuevo ambiente con promoción dev → qat → prd

Se necesita desplegar un nuevo microservicio (Lambda + API Gateway + RDS) que debe pasar por los 3 ambientes. El pipeline actual solo despliega un ambiente fijo.

Preguntas:

1. Cómo diseñar el pipeline de Azure DevOps para promover el mismo código a dev, luego qat y finalmente prd, con aprobaciones manuales antes de prd?
2. ¿Cómo manejaría las diferencias de configuración entre ambientes (tamaños, VPCs, tags) sin duplicar código Terraform?
3. En el modelo OIDC hub → deploy cross-account, cómo te aseguras de que el pipeline de dev NO pueda desplegar en la cuenta de prd? Describe el control.
4. Que estrategia de Terraform state usarías para aislar los ambientes?

Caso 1.2 — Refactor de código repetido a módulo reutilizable

Encontramos que 5 proyectos copian y pegan el mismo bloque de ~200 líneas de Terraform para crear buckets S3 con encriptación, versionado y políticas.

Preguntas:

1. Cómo convertimos eso en un módulo reutilizable versionado? ¿Dónde lo publicarías?
2. ¿Cómo versionamos el módulo para que un cambio no rompa los 5 proyectos a la vez?
3. ¿Qué harías para migrar los proyectos existentes al módulo sin recrear los buckets (sin perder datos)?

Caso 1.3 — Drift y cambio manual en producción

Alguien modifico manualmente (por consola) un Security Group que Terraform gestiona. El próximo terraform plan quiere revertirlo.

Preguntas:

1. Cómo detectar y diagnosticar el drift antes de aplicar?
2. ¿Qué decides: revertir al código o incorporar el cambio al código? ¿Cómo lo justificas?
3. ¿Cómo previenes cambios manuales en producción a futuro?

Bloque 2 — Operación, Resiliencia y Soporte (Nivel 2/3)

Evalúa: troubleshooting, causa raíz, alta disponibilidad, DRP, monitoreo.

Caso 2.1 — Incidente: latencia alta intermitente en producción

Una aplicación crítica detrás de un ALB reporta latencia alta intermitente. Los usuarios se quejan, pero el CPU de las instancias EC2 se ve normal.

Preguntas:

1. Cual seria tu proceso de diagnóstico paso a paso? ¿Qué métricas/logs revisas primero (CloudWatch, ALB access logs, RDS, etc.) y por qué?
2. Menciona al menos 4 causas raíz posibles y como descartarias cada una.
3. ¿Cómo diferenciar un problema de red, de base de datos, de aplicación o de escalado?
4. ¿Que dejarías implementado para detectar este patrón automáticamente la próxima vez?

Caso 2.2 — Resiliencia y DRP

Te piden mejorar la resiliencia de una plataforma crítica que hoy corre en una sola AZ con un RDS single-AZ.

Preguntas:

1. ¿Qué cambios harías para lograr alta disponibilidad? Ordenalos por impacto vs esfuerzo.
2. Cómo diseñarías un plan de recuperación ante desastres (DRP)? Que RTO/RPO propondrías y como los medirías?
3. ¿Cómo probarías el DRP sin afectar producción?

Caso 2.3 — Gestión de incidente con IA

Recibes un stack trace de error de una Lambda que no reconoces.

Preguntas:

1. ¿Cómo usarías IA para acelerar el diagnóstico? ¿Qué le preguntarías exactamente?
2. ¿Cómo validarías que la solución que sugiere la IA es correcta y segura antes de aplicarla en producción?
3. ¿Qué riesgos hay en aplicar directamente lo que sugiere una IA en un entorno productivo?

Bloque 3 — Gobernanza, Seguridad y FinOps

Evalúa: IAM, KMS/Secrets, WAF, least privilege, optimización de costos.

Caso 3.1 — Endurecer permisos (least privilege)

Heredas un rol IAM llamado admin-everything que varias Lambdas usan con Action: "*" y Resource: "*".

Preguntas:

1. ¿Cómo abordarías reducir ese rol a least privilege sin romper las Lambdas en producción?
2. ¿Qué herramientas/servicios de AWS usarías para descubrir qué permisos realmente usan?
3. Como automatizarías que esto no vuelva a pasar (guardrails)?

Caso 3.2 — Secretos en el código

En una revisión encuentras credenciales de base de datos hardcodeadas en variables de Terraform y en el código de una aplicación.

Preguntas:

1. Cual es tu plan de remediación inmediato y de fondo?
2. Cómo integrarías Secrets Manager o Parameter Store con la app y con el pipeline sin exponer el secreto en logs?
3. ¿Cómo rotarías esas credenciales sin downtime?

Caso 3.3 — Optimización de costos (FinOps)

El gasto mensual de AWS creció de forma sostenida. Te piden liderar la reducción.

Preguntas:

1. Cual seria tu metodología para identificar dónde está el gasto y las oportunidades (que herramientas, que orden)?
2. Antes de comprar un Savings Plan o Reserved Instance, que analizas para NO sobre-comprometerte? (piensa en cobertura, utilización, flexibilidad, tipo de pago).
3. Menciona 5 palancas de ahorro concretas y para cada una: cuando aplica y qué riesgo tiene.
4. ¿Cómo distingues una acción que realmente reduce costo de una que solo lo mueve o lo limita sin ahorrar?

Bloque 4 — Evolución, Deuda Técnica y Nuevas Tecnologías

Evalúa: visión arquitectónica, migraciones, modernización.

Caso 4.1 — Migración / modernización

Tienes un cluster de base de datos de generación antigua que AWS anunció que será reemplazado por una nueva generación más barata y rápida (mismo motor, nueva familia de nodos/instancias).

Preguntas:

1. Como planearias la migración minimizando riesgo y downtime?
2. Que validarias ANTES de migrar (capacidad, compatibilidad, features, costo real)?
3. Como confirmarias DESPUÉS que el ahorro es real y que no se degrade el rendimiento? Qué datos usarías?
4. ¿Qué plan de rollback dejarías listo?

Caso 4.2 — Deuda técnica

Identificas un job de procesamiento de datos (ETL) que cuesta mucho y tiene errores recurrentes en los logs, pero "funciona".

Preguntas:

1. ¿Cómo priorizarías atacarlo frente a otras tareas? ¿Cómo lo justificas ante tu jefe?
2. Cómo distinguir la causa raíz del costo (ej. sobredimensionamiento, reprocesamiento, errores que consumen recursos) de los síntomas?
3. ¿Qué propondrías sin romper la operación actual?

Bloque 5 — Ingeniería de Datos y Almacenamiento a Gran Escala

Evalua: Data Lakes, Glue, Athena, Redshift, S3 lifecycle, backups.

Caso 5.1 — Data Lake y consultas

Se quiere habilitar analítica sobre datos que hoy están en S3 (formato Parquet/Iceberg).

Preguntas:

1. ¿Qué arquitectura propondrías (Glue Catalog, crawlers, Athena, Redshift)? ¿Cuándo usar cada uno?
2. ¿Cómo optimizamos los costos de las consultas (particionamiento, formato, compresión)?
3. ¿Cómo controlar quién accede a qué datos (gobernanza de acceso)?

Caso 5.2 — Ciclo de vida y retención

Tienes petabytes de datos en S3 con costo creciente y requisitos de retención regulatoria.

Preguntas:

1. ¿Cómo diseñar las políticas de lifecycle (transiciones a IA, Glacier, Deep Archive)?
2. ¿Cómo balanceas el costo de almacenamiento vs el costo/tiempo de recuperación?
3. ¿Cómo automatizamos respaldos consistentes de bases de datos con AWS Backup alineado a retención regulatoria?

Bloque 6 — Redes, Conectividad Híbrida y DRP Cross-Región

Evalúa: Cloud WAN, segmentación, inspección de tráfico, conectividad híbrida (DX/VPN), failover automático, DRP multi-región. Contexto real de la operación de la compañía.

Contexto adicional: La compañía migró de Transit Gateway a **AWS Cloud WAN** con una arquitectura multi-región (Virginia primaria us-east-1, Oregon DRP us-west-2). La inspección de tráfico se hace con **FortiGate** (send-via este-oeste, send-to egreso internet). La conectividad híbrida on-premise usa **Direct Connect (primario) + VPN Site-to-Site (backup)**. Existe segmentación por ambiente (dev/qat/prd) y por tipo de enlace.

Caso 6.1 — Failover de conectividad híbrida (DX ↔ VPN)

Una carga productiva se conecta a on-premise vía Direct Connect (primario) con VPN como respaldo. Te piden garantizar el failover automático sin routing asimétrico.

Preguntas:

1. Cómo diseñarías la segmentación en Cloud WAN para que el DX y la VPN NO compitan por prioridad de ruta y causen tráfico asimétrico (que el firewall descarta)?
2. Que mecanismo detecta la caída del DX y cuánto tiempo tomaría converger a la VPN?
3. Un segmento de aplicación (prd) necesita alcanzar on-premise a través del segmento del enlace. Si el share entre segmentos es NO transitivo, cómo te aseguras de que prd, shrprd y epsprd alcancen on-premise?
4. Como validarías (con datos) que el failover funciona antes de declararlo listo?

Caso 6.2 — Inspección de tráfico y alta disponibilidad del firewall

El tráfico este-oeste y el egreso a internet deben pasar SIEMPRE por inspección (FortiGate). No puede haber tráfico que evada la inspección durante un failover.

Preguntas:

1. ¿Cómo garantizas que ningún tráfico evada la inspección durante un evento de failover regional o de un appliance?
2. El firewall usa dos peers BGP (uno por ENI de Cloud WAN) para HA. ¿Qué pasa si uno de los peers queda configurado pero NO establecido (never Active)? ¿Qué riesgo introduce a nivel de routing del segmento completo?
3. Como diagnosticamos un segmento cuyo tráfico de repente cae en estado BLACKHOLE?

4. En egreso a internet, que puertos permitirías y cuales bloquearías por defecto? Justifica.

Caso 6.3 — Conexión y failover entre regiones

Ante una falla de la región primaria (Virginia), el tráfico debe redirigirse a la región DRP (Oregon) automáticamente.

Preguntas:

1. Cómo interconectarías Virginia y Oregon para propagación automática de rutas sin usar TGW Peering ni VPN inter-region? ¿Qué requisitos tienen los segmentos para operar en ambas regiones?
2. Que detecta la falla regional y que mecanismo redirige el tráfico a Oregon? Cual sería un RTO realista?
3. Cómo evitarías que dev/qat consuman recursos DRP innecesariamente (solo prd debe tener cross-region)?

Caso 6.4 — DRP por tipo de servicio

Debes definir la estrategia DRP para distintas cargas: una base de datos relacional core, un cluster EKS, instancias EC2, funciones Lambda y una base de datos on-premise con réplica en AWS.

Preguntas:

1. Para cada uno (RDS/Aurora, EKS, EC2, Lambda, DynamoDB, S3), que estrategia DRP propondrías (pilot light, warm standby, active-active, etc.) y por qué? Considera costo vs RTO/RPO.
2. Para una base de datos core cuyo publisher está on-premise y tiene réplicas de lectura en AWS (Virginia y Oregón), como garantizas que la réplica de Oregon siga disponible si cae Virginia? ¿Qué conectividad usa?
3. Como diseñarías que cada cuenta nueva que se migra a Cloud WAN "herede" automáticamente la segmentación, inspección, conectividad on-premise y DRP, sin configuración manual cuenta por cuenta?
4. ¿Cómo probarías el DRP completo (RTO/RPO reales) sin afectar producción?

Bloque 7 — Escenario Integrador (Live / Whiteboard)

Evalúa: pensamiento integral bajo escenario realista.

Escenario

La compañía va a lanzar un nuevo producto financiero que espera picos de tráfico variables. Debe correr en AWS (organización multi-cuenta con Cloud WAN), con IaC, desplegarse vía Azure DevOps (OIDC), ser resiliente (DRP cross-región), seguro (tráfico inspeccionado) y con costos controlados. Necesita conectarse a una base de datos core que vive on-premise. Aún no existe nada de este producto.

Diseña alto nivel / whiteboard:

1. **Arquitectura:** que servicios usarias para compute, datos, red, seguridad y por que.
2. **Red y conectividad:** como conectas la nueva cuenta a Cloud WAN, como llegaría a on-premise (DX/VPN), y cómo garantizamos que su tráfico pase por inspección (FortiGate).
3. **IaC + CI/CD:** como estructurarías los módulos Terraform y el pipeline con la cadena OIDC hub → deploy cross-account para dev/qat/prd.
4. **Seguridad:** IAM least privilege, KMS, WAF, secretos, inspección este-oeste y egreso.
5. **Resiliencia y DRP:** multi-AZ, escalado, backups, estrategia DRP cross-región (Virginia → Oregon) según el tipo de dato/servicio.
6. **Observabilidad:** qué métricas, alarmas y logs dejarías desde el día 1 (incluye salud de BGP/conectividad e inspección).
7. **FinOps:** como controlar el costo desde el diseño y que revisarías mensualmente.

Preguntas de profundización::

- Si el tráfico se duplica de un día para otro, ¿que se rompe primero y como lo previenes?
- Si un componente de red (ej. NAT Gateway o el enlace DX) empieza a costar mucho o falla, como lo optimizas/recuperas?
- ¿Cómo te aseguras de que la nueva cuenta herede automáticamente segmentación, inspección, conectividad on-premise y DRP al integrarse a Cloud WAN?
- ¿Cómo harías un cambio en producción un viernes a las 5pm de la forma más segura posible?
- Si cae la región Virginia, describe minuto a minuto que pasa y que RTO lograrías.